```
library(forecast)
library(tseries)
library(fUnitRoots)#用于单位根检验
```

第一题

模拟一ARMA（4,1）模型如下，n=100
$X_t = 1.16X_{t-1} - 0.37X_{t-2} - 0.19X_{t-3} + 0.18X_{t-3} + \epsilon_t + 0.5\epsilon_{t-1}, \epsilon \sim iidN(0,4)$ 利用此模拟序列 1.利用ACF和PACF直观判断重新建模

```
#模拟序列
ts1=arima.sim(list(order=c(4,0,1),ar=c(1.16,-0.37,-0.19,0.18),ma=0.5),sd=2,n=1
00)
plot.ts(ts1)
par(mfrow=c(1,2))
acf=acf(ts1)
pacf=pacf(ts1)
par(mfrow=c(1,1))
#利用ACF和PACF重新建模
q=which(abs(acf$acf)<0.2)[1]-1
p=which(abs(pacf$acf)<0.2)[1]-1
print(paste0("模型为arma(",p,",",q,")"))
fit1=arima(ts1,order=c(p,0,q))
fit1
```

2.利用R软件auto.arima自动选择模型（可以选AIC，也可以选BIC）

```
#选用AIC
fit2=auto.arima(ts1)
fit2
```

3.直接估计ARMA（4,1），与前两个模型比较，选择一个你认为最优的模型。

```
fit3=arima(ts1,order=c(4,0,1))
#用AIC来选择最优模型（因为三个拟合均有AIC）
AIC=c(fit1$aic,fit2$aic,fit3$aic)
best=order(AIC)[1]
print(paste0("我们用AIC判断模拟好坏，可知第",best,"个模型是最好的"))
```

第二题

1.拟合序列c=0.1，n=1000$X_t = c + X_{t-1} + \epsilon_t, \epsilon_t \sim iidN(0,1)$考察该序列差分后残差序列和提取线性趋势后残差的波动性。

```
c=0.1
n=1000
ts2_1=c(0)
for(i in 1:n)
  ts2_1[i+1]=c+ts2_1[i]+rnorm(1)
ts2_1=ts2_1[-1]
par(mfrow=c(2,2))
plot(ts2_1,type="l")
ts2_1_diff=diff(ts2_1,1)
plot(ts2_1_diff,type="l")
print("差分")
#波动幅度（方差）为
var(ts2_1_diff)
adf.test(ts2_1_diff)
Box.test(ts2_1_diff,lag=log(length(ts2_1_diff)))
print("p-value均较小，无单位根但残差不独立")
x=1:n
lm2_1<-lm(ts2_1~x)
res2_1=lm2_1$res
print("线性")
#波动幅度（方差）为
var(res2_1)
plot(res2_1,type="l")
adf.test(ts2_1_diff)
Box.test(res2_1,lag=log(length(res2_1)))
print("p-value均较小，无单位根且独立，可看成白噪声")
```

2.拟合序列c=0，b=0.1，n=1000$X_t = c + bt + \epsilon_t, \epsilon_t \sim iidN(0,1)$考察该序列差分后残差序列和提取线性趋势后残差的波动性。

```
c=0
b=0.1
n=1000
ts2_2=numeric(0)
for(i in 1:n)
  ts2_2[i]=c+b*i+rnorm(1,sd=10)
ts2_2_diff=diff(ts2_2,1)
par(mfrow=c(2,2))
plot(ts2_2,type="l")
plot.ts(ts2_2_diff)
print("差分")
#波动幅度（方差）为
var(ts2_2_diff)
adf.test(ts2_2_diff)
Box.test(ts2_2_diff,lag=log(length(ts2_2_diff)))
print("p-value均较小，无单位根且独立，可看成白噪声")
x=1:n
lm2_2<-lm(ts2_2~x)
```

```
res2_2=lm2_2$res
print("线性")
#波动幅度（方差）为
var(res2_2)
plot(res2_2,type="l")
adf.test(res2_2)
Box.test(res2_2,lag=log(length(res2_1)))
print("p-value均较小，无单位根但残差不独立")
par(mfrow=c(1,1))
```

可以看出两重拟合在不同的模型中的残差检验效果不同

第三题

读入数据http://anson.ucdavis.edu/~shumway/recruit.dat,

```
#一些函数

#获取gamma的估计值
getgamma<-function(x,p)
{
  gamma=numeric(0)
  y=scale(x,scale=FALSE)
  n=length(x)
  for(k in 0:p)
    gamma=c(gamma,sum(y[1:(n-k)]*y[(k+1):n])/n)
  return(gamma)
}#getgamma

#用Yule_Walker方程估计参数
Yule_Walker<-function(x,p)
{
  mygamma=getgamma(x,p)
  #Fn
  Fn=matrix(nrow=p,ncol=p)
  for(i in 1:p)
    for(j in 1:p)
      Fn[i,j]=mygamma[abs(i-j)+1]
  an=solve(Fn)%*%mygamma[2:(p+1)]
  sigma0=mygamma[1]-sum(an*mygamma[2:(p+1)])
  sigma0
  return(c(an,sigma0))
}#Yule_Walker

#用极大似然估计
MLE<-function(t,p)
{
  N=length(t)
  y=t-mean(t)
```

```
  Y=y[-1:(-p)]
  X=matrix(ncol=p,nrow=N-p)
  for(i in 1:p)
    X[,i]=y[(p-i+1):(N-i)]
  fit=solve(t(X)%*%X)%*%t(X)%*%Y
  S=sum((Y-X%*%fit)^2)
  sigma0=S/(N-p)
  return(c(fit,sigma0))
}#MLE
```

1. 画出acf和pacf，进行定阶和模型

```
par(mfrow=c(1,1))
t=read.table("http://anson.ucdavis.edu/~shumway/recruit.dat")
t=ts(t)
plot.ts(t)
par(mfrow=c(1,2))
acf(t)
pacf(t)
```

2. 利用arima估计模型

```
#acf拖尾，pacf可以看成2阶截尾，考虑AR(2)
adfTest(t,lags=2)
print("认为序列是平稳的，没有单位根")
#用ARIMA(2,0,0)估计
arima(t,order=c(2,0,0))
```

3. 采用auto.arima自动选择模型，并作比较

```
#用auto.arima
auto.arima(t)
print("用ARIMA(1,1,0),但ACI值并不比AR(2)模型低")
```

4. 分别采用Yule-Walker方程和极大似然估计估计参数，并作比较。

按照AR(2)估计参数

```
##Yule-Walker方程估计
fit_Y=Yule_Walker(t,2)
#系数估计为
fit_Y[-3]
#sigma估计为
fit_Y[3]

##极大似然估计
fit_M<-MLE(t,2)
#系数估计为
fit_M[-3]
#sigma估计为
fit_M[3]
```

按照ARIMA(1,1,0)估计参数

```
##Yule-Walker方程估计
fit_Y=Yule_Walker(diff(t,1),1)
#系数估计为
fit_Y[-2]
#sigma估计为
fit_Y[2]

##极大似然估计
fit_M=MLE(diff(t),1)
#系数估计为
fit_M[-2]
#sigma估计为
fit_M[2]
```

两个估计的系数相差不大，Yule-Walker方程估计的方差估计较大，而极大似然偏小

第四题

考虑美国的国民生产总值(GNP)经过季节调整后的对数值。 时间是1947年第 一季度到2010年第一季度，总计253个观测值。读入数据q-gnp4710.txt并计算季节调整后的GNP的对数值, 进行单位根检验，并建立模型。

```
GNP<-read.table("/Users/rain/Desktop/2018-2/时间序列/上机/ftsdata/q-gnp4710.txt",header=TRUE)
gnp <- ts(GNP[["VALUE"]], start=c(1947, 1), frequency=4)
par(mfrow=c(1,1))
plot.ts(gnp)
#去掉季节项后取对数
gnp_nosea<-log(gnp-decompose(gnp)$season)
plot.ts(gnp_nosea)
#从图中可看出有明显趋势
adf.test(gnp_nosea)
```

```
print("有单位根,不平稳，做差分")
dgnp <- diff(gnp_nosea)
adf.test(dgnp)
print("无单位根,平稳，根据ACF和PACF定阶")
par(mfrow=c(1,2))
acf(dgnp)
pacf(dgnp)
#acf拖尾，pacf截尾，我们定为AR(16)
arima(dgnp,order=c(16,0,0))
```

第五题

美国月失业率数据进行建模和预测，数据来自Department of Labor, US Beareau of Labor Statistics。数据经过了季节调整。 失业率为百分数(单位是%)， 是16周岁及以上的失业人口比例。数据m-unrate.txt， 进行单位根检验，使用arima进行建模，尝试模型$ARIMA(1,1,(1,5,12))$，$ARIMA(1,1,5)\times(1,0,1)_{12}$,$ARIMA(1,1,5)\times(0,1,0)_{12}$，（也可以自己找一个合适的模型）选择一个模型，并做预测。

```
unrate<-read.table('/Users/rain/Desktop/2018-2/时间序列/上机/ftsdata/m-unrate.txt',header=TRUE)
unrate<-ts(unrate$rate,start=c(1948,1,1),freq=12)
#1948-2009进行建模
plot.ts(unrate)
unrate_train<-window(unrate,end=c(2009,12))
#2009-2010进行验证
unrate_validate<-window(unrate,start=c(2010,1))
par(mfrow=c(1,1))
plot.ts(unrate_train)
par(mfrow=c(1,2))
acf(unrate_train)
pacf(unrate_train)
adfTest(unrate_train,type="nc",lags=6)
#存在单位根，不平稳，做一次差分
unrate_train_diff=diff(unrate_train)
par(mfrow=c(1,1))
plot.ts(unrate_train_diff)
par(mfrow=c(1,2))
acf(unrate_train_diff)
pacf(unrate_train_diff)
#acf和pacf均拖尾，又有较明显的“季节性”，可考虑季节ARMA
adf.test(unrate_train_diff)
#差分后平稳
```

模型$ARIMA(1,1,(1,5,12))$

```
fit1<-
arima(unrate_train,order=c(1,1,12),transform.pars=FALSE,fixed=c(NA,NA,rep(0,3)
,NA,rep(0,6),NA))
fit1
tsdiag(fit1)
```

可以看出该模型的残差不为白噪声

模型$ARIMA(1,1,5)\times(1,0,1)_{12}$

```
fit2<-arima(unrate_train,order=c(1,1,5),seasonal=c(1,0,1))
fit2
tsdiag(fit2)
```

可以将该模型的残差看成白噪声

模型$ARIMA(1,1,5)\times(0,1,0)_{12}$

```
fit3<-arima(unrate_train,order=c(1,1,5), seasonal=list(order=c(0,1,0),
period=12))
fit3
tsdiag(fit3)
```

可以将该模型的残差看成白噪声

利用auro.arima建模

```
fit4<-auto.arima(unrate_train)
fit4
tsdiag(fit4)
```

该模型的残差独立性一般，并未很高

选择模型并预测

```
AIC=c(fit1$aic,fit2$aic,fit3$aic,fit4$aic)
best=order(AIC)[1]
print(paste0("我们用AIC判断模拟好坏，可知第",best,"个模型是最好的"))
print(paste0("用第",best,"个进行预测"))
fited<-forecast(fit2,h=9)
plot(fited)
lines(unrate_validate,col="red",lwd=2)
```

实际值均在95%的范围内，故认为拟合结果较好

第六题

例题： Y-W估计和LS估计的模拟比较。设ϵ_t取为标准正态白噪声， 模拟产生AR(4)序列
$X_t = 1.16X_{t-1} - 0.37X_{t-2} - 0.19X_{t-3} + 0.18X_{t-3} + \epsilon_t \ t = 1 : N$ 分别取
$N = 20, 100, 400, 1600$， 重复M次产生模拟数据并分别用Y-W方法和最小二乘方法估计参数。

```
#生成AR(4)序列
gen_ar_6=function(num)arima.sim(list(order=c(4,0,0),ar=c(1.16,-0.37,-0.11,0.18
)),n=num)
num=c(20,100,400,1600)
result=sapply(num,function(n){
  res=sapply(1:1000,function(o){
    x=gen_ar_6(n)
    #用Yule_Walker方程估计
    a=Yule_Walker(x,4)
    #用最小二乘法估计
    b=MLE(x,4)
    c(a,b)
  })
  c(apply(res,1,mean),apply(res,1,sd))
})
#输出结果
dimnames(result)<-
list(c(rep(c(paste0("ave_a",1:4),"ave_sigma"),2),rep(c(paste0("std_a",1:4),"st
d_sigma"),2)),c("n=20","n=100","n=400","n=1600"))
Yule_ave<-t(result[1:5,])
Yule_std<-t(result[11:15,])
MLE_ave<-t(result[6:10,])
MLE_std<-t(result[16:20,])
Root=t(sapply(1:4,function(o){
  c(polyroot(c(1,-Yule_ave[o,-5])),polyroot(c(1,-MLE_ave[o,-5])))
}))
dimnames(Root)<-
list(c("n=20","n=100","n=400","n=1600"),c("Root_Yule",rep("",3),"Root_MLE",rep
("",3)))
print("Yule_Walker估计为")
Yule_ave
Yule_std
print("最小二乘估计为")
MLE_ave
MLE_std
print("特征值为")
Root[,1:4]
Root[,5:8]
```

得到和书上例题相同的结果
在回归系数方面，Yule-Waker估计的标准差较小，但两个估计的标准差较小，故两个估计都是相合的，在N较大时两个估计的精度相近。且该AR(4)模型满足最小相位条件