中国科学技术大学

时间序列分析

中国科学技术大学

时间序列分析课程论文

作者姓名: 严梓瑞、肖泉

学科专业: 统计与金融

导师姓名: 陈昱 教授

完成时间: 二○一九年七月九日

University of Science and Technology of China

Time Series

TIme Series Course Work

Author: Zirui Yan, Quan Xiao

Speciality: Statistics and Finance

Supervisor: Prof. Yu Chen

Finished time: July 9, 2019

摘　要

本文主要研究了近十年美国加州地区飞机晚点率与延误率的时间序列。文章将对预处理后的数据采用 ARIMA 模型拟合并进行残差诊断，再用 GARCH 模型对波动率建模并做预测。最后，根据数据分析结果得出结论并分析原因。

关键词：加州地区；飞机晚点率；延误率；ARIMA 模型；GARCH 模型；模型拟合；数据分析

ABSTRACT

This paper mainly studies the time series of aircraft late rate and delay rate in California in the past decade. The article will use the ARIMA model to fit the pre-processed data and perform residual diagnosis, and then use the GARCH model to model and predict the volatility. Finally, based on the results of the data analysis, the conclusions are drawn and the reasons are analyzed.

Key Words: California; aircraft late rate; delay rate; ARIMA model; GARCH model; model fitting; data analysis

目　录

第 1 章　简介 · · ·

第 1 章　简　　介

1.1　问题介绍

随着经济的发展，飞机越来越多地出现在了人们的出行方式中，它的高效率使得长途旅行成为可能，与世界各个角落的联系愈发紧密。但是，飞机相比其他交通方式的高延误率也使得使得航空快速旅行的经济价值大打折扣，成为航空运输服务满意度的天敌。

客观来说，航班延误往往具有不可预知性和随机性，极端天气、空中管制、飞行距离等都是它的影响因素。因此，美国运输部对航班延误的规定是：航班在计划时间的 15 分钟后离开（或到达）乘客登机区域才为延误。事实上，无论是到达延误还是离开延误都让乘客，尤其是时间紧迫的旅客抱怨颇多。

本文旨在利用美国国家交通局的统计数据，分析到达延误率和离开延误率的时间序列，建立模型并作出预测。通过对延误率在时间频度的解读与预测，本文将为乘坐飞机的旅客提供在不同时间选择航班的办法，并为航空公司合理分配资源提供理论依据。

1.2　数据选择

本文数据来自美国国家交通局 https://www.transtats.bts.gov。考虑到地区气候的差异性，本文挑选了加州地区 2010 年 1 月-2019 年 4 月的航班数据进行研究，其中 2010 年 1 月到 2018 年 12 月的数据为训练集，测试集为 2019 年前四个月的数据，最终预测 2019 年的剩余月份。

本文利用数据中的预计到达与实际时间的差值与预计离开与实际时间的差值计算出到达延误率 ARR_DELAY 与离开延误率 DEP_DELAY。设当天到达，离开的航班数分别为 l_1 和 l_2，第 i 架航班到达和离开差值分别为 t_{1i} 和 t_{2i}，则其计算式为

$$ARR_DELAY = \frac{\sum_{i=1}^{l_1} I(t_{1i} \geqslant 15)}{l_1}, \qquad DEP_DELAY = \frac{\sum_{i=1}^{l_2} I(t_{2i} \geqslant 15)}{l_2}$$

其中，$I(x)$ 为示性函数。

由于将到达延误率和离开延误率按日期排列可看做是时间序列[?]，因此本文将对这两个时间序列进行分析建模。

1.3　章节安排

首先，了解数据集的变量含义并选出部分有意义的变量做平稳性检验、零均值检验和白噪声检验，见第二章。

其次，对预处理后的数据进行建模。通过对自相关系数与偏相关系数的分析，选择 ARIMA 模型并定阶，做残差诊断，见第三章。

再次，检验 ARCH 效应并对数据波动率用 GARCH 模型建模，进一步检验 TGARCH 效应并用 TGARCH 模型建模并做残差诊断，见第四章。

接着，对数据进行预测并评价预测效果，选择出最终模型相关内容见第五章。

最后第六章对出发的延误率进行了相同的分析并得出结果，第七章简要分析了我们得出的模型，根据模型的拟合结果，联系实际，分析飞机延误率的影响因素，先出较优模型，对乘坐飞机出行的旅客提出建设性意见。

文章中使用的部分代码见附录。

第 2 章　数据预处理

2.1　原始变量加工

在数据中挑选出与研究目标有关的原始变量，如表 4.1。

表 2.1　原始变量及解释

变量名称	描述
FL_DATE	航班日期（年-月-日）
DepDelay	计划和实际出发时间的差值（单位：分钟）。提前离开显示负数。
ArrDelay	计划和实际到达时间的差值（单位：分钟）。提前到达显示负数。

利用 1.2 节公式计算出航班延误率，并建立时间序列，名称及解释如表 2.2。分别作出两个时间序列的图像，如图 2.1， 2.2

表 2.2　时间序列名称及解释

时间序列名称	描述
DEP_DELAY	出发时间延误率。
ARR_DELAY	到达时间延误率。

由图像可以看出两个时间序列趋势差不多，故后文只分析到达延误率，起飞延误率同理，只附结果。

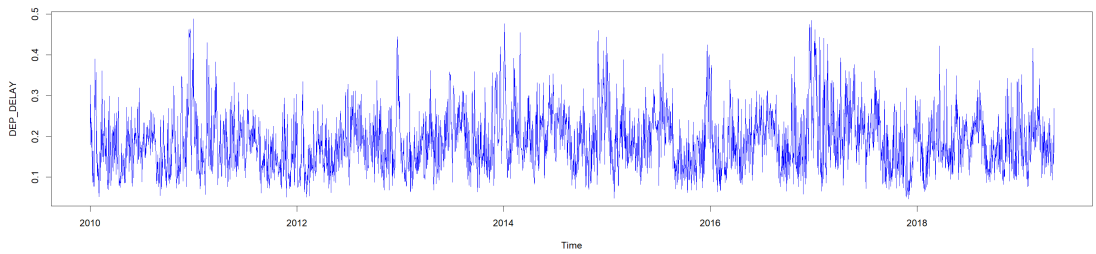

图 2.1　起飞延误率

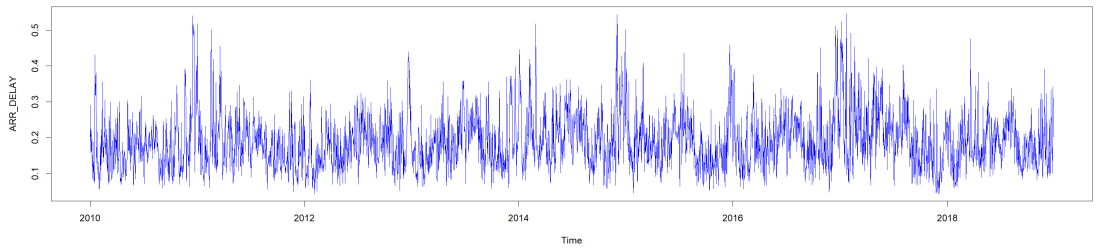

图 2.2　到达延误率

2.2　自相关系数与偏相关系数

由于延误率受到天气影响，而天气又具有时间上的局部相关性，如一段时间内强降雨较为频繁，故猜测延误率具有一定的自相关性。到达延误率的自相关系数与偏相关系数图如 2.3， 2.4所示。

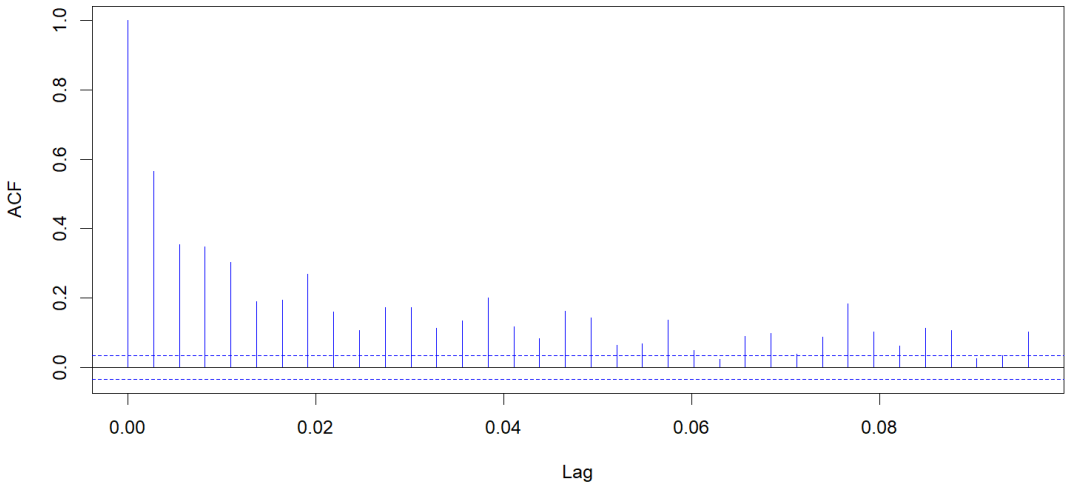

图 2.3　到达延误率自相关系数图

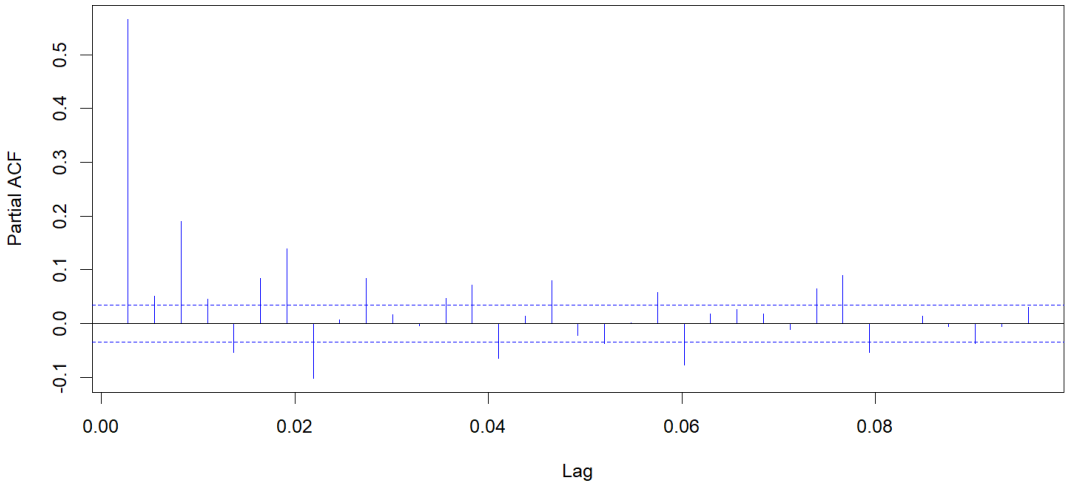

图 2.4　到达延误率偏相关系数图

分析图像可知，到达延误率的自相关系数和偏相关系数均拖尾，且偏相关系数有一定的周期性。

考虑对序列做一阶差分消除自相关性，得到的自相关系数与偏相关系数图如 2.5， 2.6所示。可以看出自相关系数有明显的周期性，近似截尾，偏相关系数

拖尾。

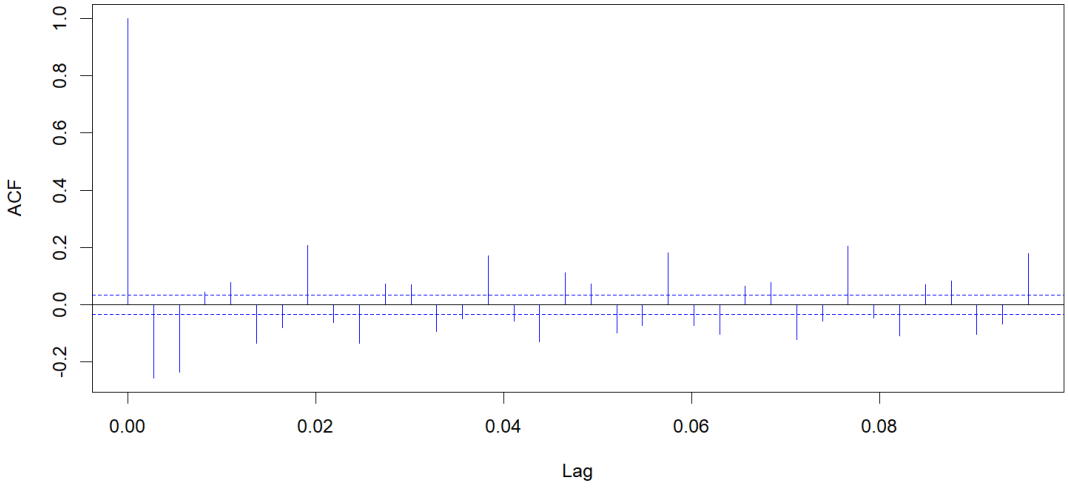

图 2.5　到达延误率一阶差分自相关系数图

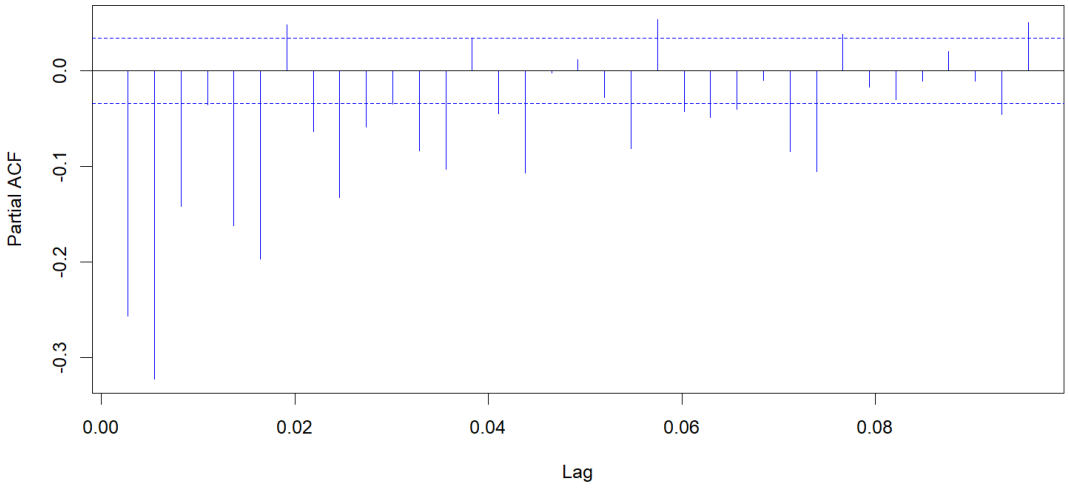

图 2.6　到达延误率一阶差分偏相关系数图

2.3　平稳性检验

从到达延误率的时序图可以大致看出该时间序列不平稳，更加精细地，我们用 Dickey-Fuller 检验，得到 p 值为 0.1998，大于 0.05，故有单位根，序列不平稳。考虑对序列做一阶差分再进行单位根检验，此时 p 值小于 0.01，故拒绝有单位根的原假设，序列平稳。一阶差分时序图见图 2.7。

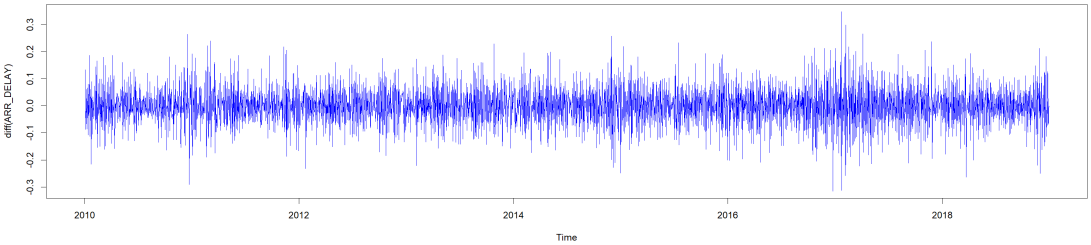

图 2.7　到达延误率一阶差分时序图

2.4　均值为零的检验

用 t 检验检验到达延误率均值是否为零，检验 p 值小于 $2.2e^{-16}$，认为到达延误率显著非零。进一步，由检验也可得到到达延误率的 95% 置信区间 [0.187, 0.192]。

对差分后的数据进行均值为零的检验，检验 p 值为 0.9918，故认为一阶差分后到达延误率均值为零。

2.5　白噪声检验

对一阶差分后的到达延误率序列用 Ljung-Box 检验进行白噪声检验，得到 p 值小于 $2.2e^{-16}$，显著拒绝是白噪声的假设。

第 3 章　ARIMA 建模

3.1　模型拟合

由 2.2 节的自相关系数与偏相关系数的分析，可尝试用 ARIMA 模型对到达延误率序列进行拟合。用 R 函数 *auto.arima* 以 AIC 为准则初步拟合得到 ARIMA(5,1,2) 模型, 记为模型一:

$x_t = 0.328x_{t-1} + 0.042x_{t-2} + 0.141x_{t-3} + 0.096x_{t-4} - 0.068x_{t-5} + \epsilon_t - 0.807\epsilon_{t-1} - 0.176\epsilon_{t-2} \quad \epsilon_t \sim N(0, 0.004)$

以 BIC 为准则拟合得到 ARIMA(3,1,1)，记为模型二:

$x_t = 0.512x_{t-1} - 0.060x_{t-2} + 0.175x_{t-3} + \epsilon_t - 0.988\epsilon_{t-1} \quad \epsilon_t \sim N(0, 00.004)$

对两个模型的残差进行检验，得到的结果如图 3.1，图 3.2所示。相比之下，模型一较好，因为 LB 白噪声检验时，它有更多的点不显著。

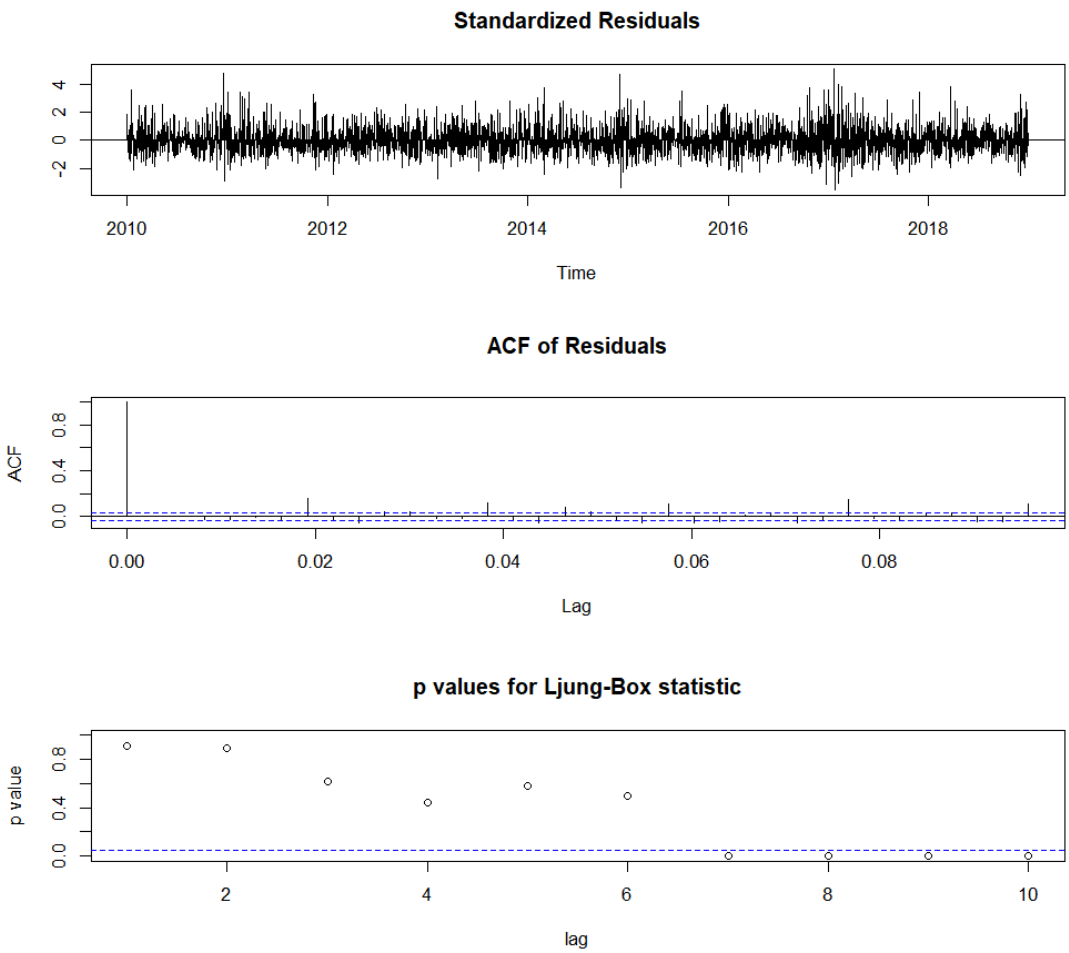

图 3.1　模型一残差分析图

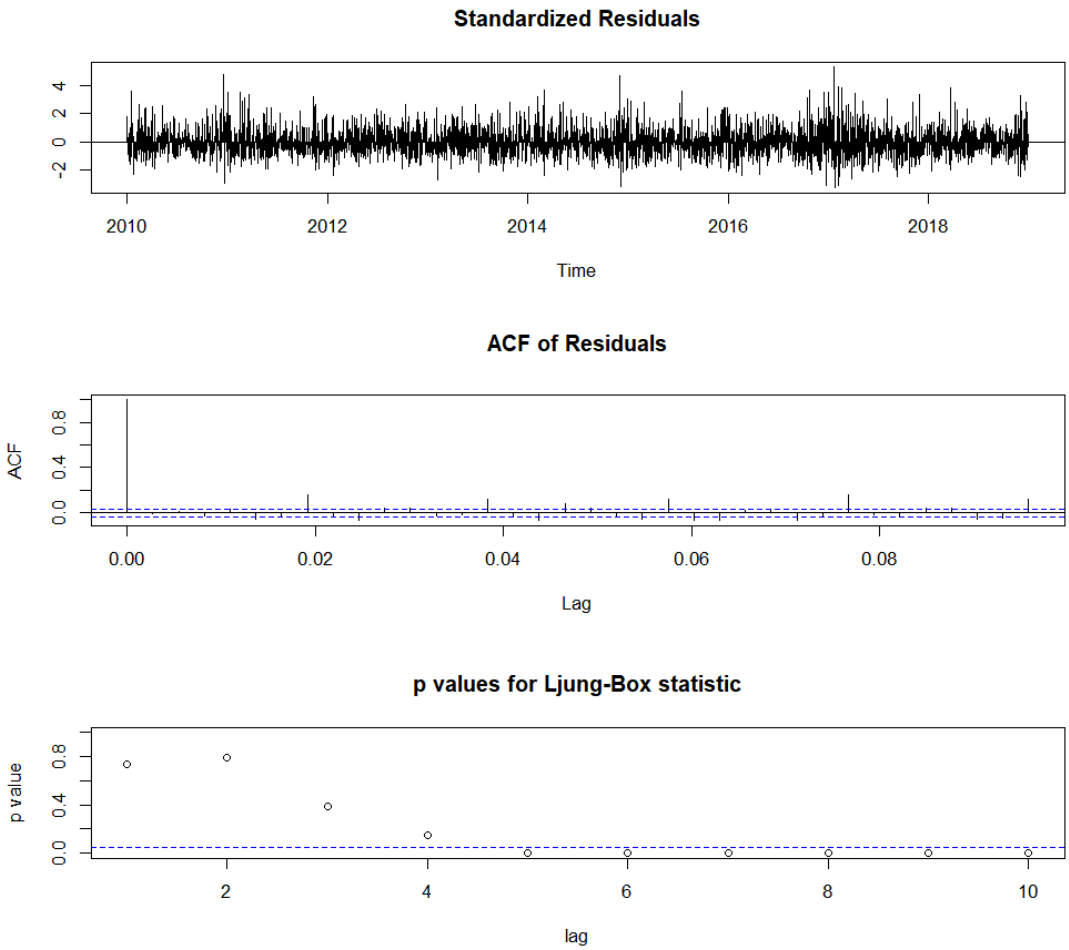

图 3.2　模型二残差分析图

考虑季节 ARIMA 模型由于做一阶差分后的 ACF 和 PACF 大概出现了 7 的周期, 见图 3.3和图 3.4

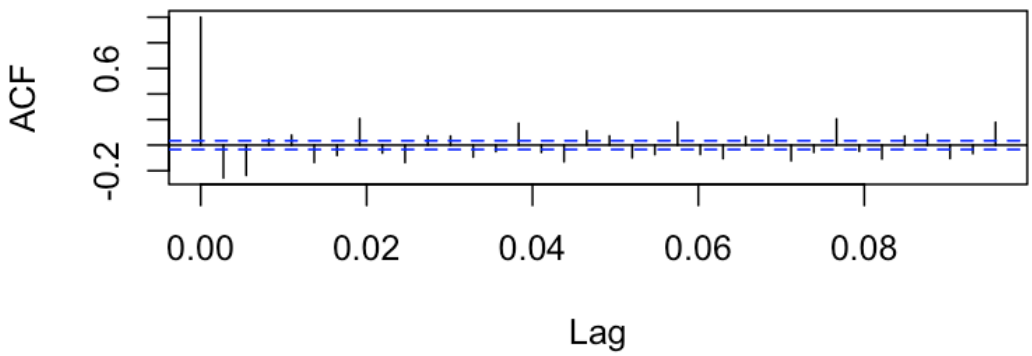

图 3.3　差分后的 acf

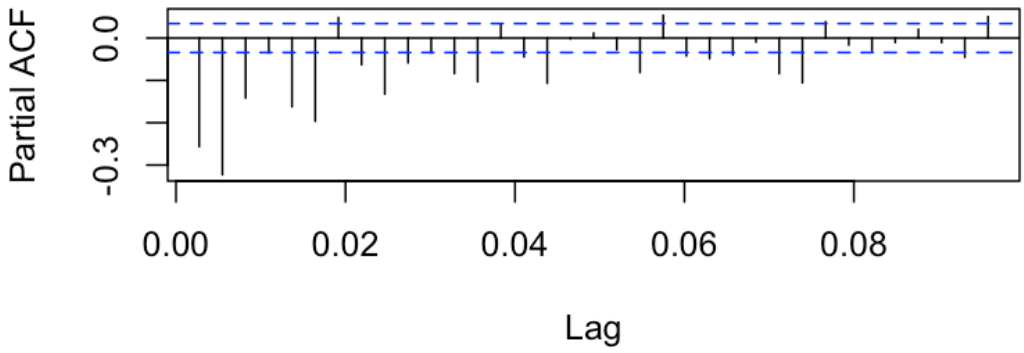

图 3.4　差分后的 pacf

因此我们考虑拟合季节 ARIMA 模型，AIC 和 BIC 拟合出来均为 ARIMA(1,1,1)(0,0,2)[7] 模型，该模型的参数见表 3.1，残差分析见图 3.5。

表 3.1　季节 ARIMA 参数

ar1	ma1	sma1	sma2
0.5318	-0.9881	0.1762	0.1050

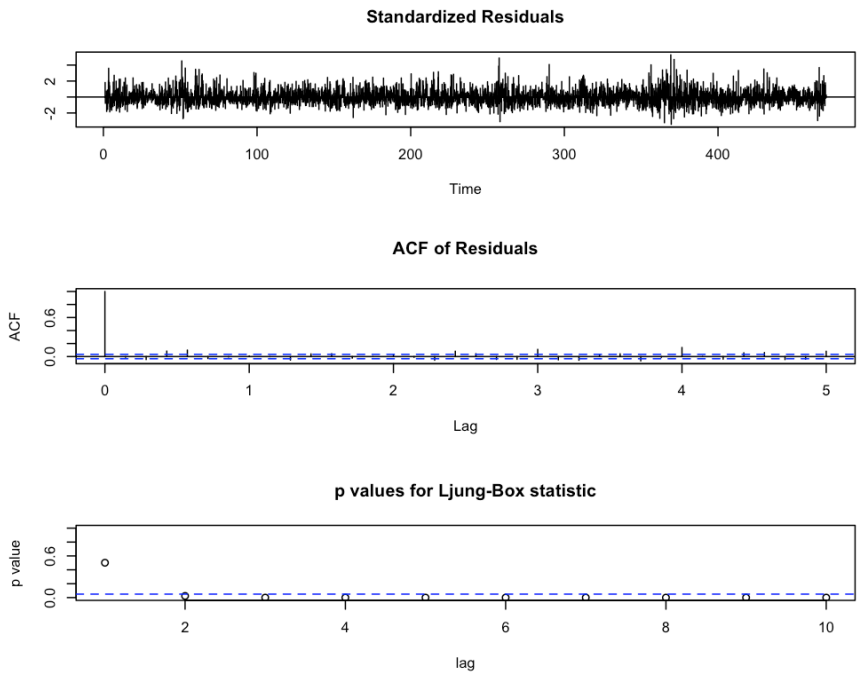

图 3.5　季节 ARIMA 残差分析图

难以通过残差的白噪声检验，但是残差的 ACF 图较好，原因为其 PACF 不截尾，我们会在未来章节说明单一的这个模型拟合并不佳。

第 4 章　波动率建模

本章以模型一为例，考虑波动率建模

4.1　ARCH 效应检验

用 Box.test 进行 ARCH 效应检验，结果如下

表 4.1　ARCH 效应检验

模型	p 值
模型一	6.183e-11
模型二	1.705e-10

故均有明显的 ARCH 效应 (LM 检验得到相同结果), 考虑用 ARIMA-GARCH 模型进行拟合，我们列举其中几个模型并进行适当的分析。
以下考虑的序列为做一次差分后的序列，为表示方便仍以 x_t 表示差分后的序列，因此 ARIMA(5,1,2) 对于差分后的序列为 ARIMA(5,0,2)

4.2　ARCH 模型

考虑残差平方的 PACF 来对 ARICH 定阶,PACF 图如 4.1，PACF 不截较晚，但我们可以考虑 ARCH(4) 或 ARCH(7)（或 ARCH(3)）。

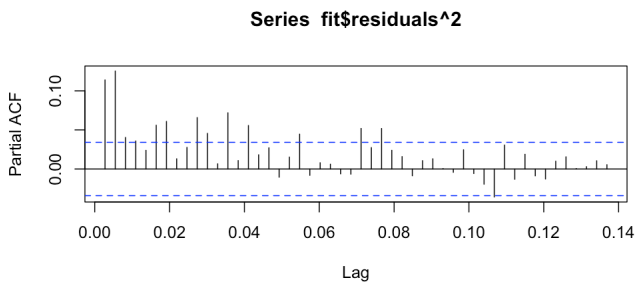

图 4.1　残差平方的 pacf

我们考虑拟合 ARIMA(5,1,2)-ARCH(4), 模型为 $x_t = 0.310x_{t-1} + 0.032x_{t-2} + 0.158x_{t-3} + 0.116x_{t-4} - 0.058x_{t-5} + a_t - 0.808a_{t-1} - 0.183a_{t-2}$　$a_t = \delta_t\epsilon_t$　$\epsilon_t \sim N(0,1)$
$\delta_t = 0.003 + 0.131a_{t-1}^2 + 0.082a_{t-2}^2 + 0.044a_{t-3}^2 + 0.043a_{t-4}^2$

QQ 图如 4.2，可以看出残差的正态性较差, 虽然所有的变量 p 值都是较小

的，残差 QQ 图没有显著的改善，考虑 std 和 sstd 分布。

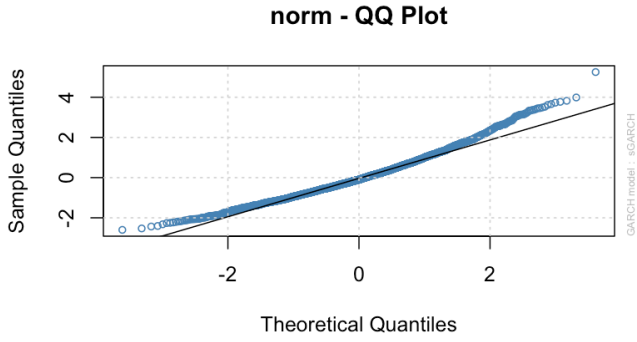

图 4.2　ARIMA(5,1,2)-ARCH(4) QQ 图

新息为 std 分布模型为

$x_t = 0.248x_{t-1} + 0.035x_{t-2} + 0.146x_{t-3} + 0.125x_{t-4} - 0.044x_{t-5} + a_t - 0.797a_{t-1} - 0.192a_{t-2} \quad a_t = \delta_t\epsilon_t \quad \epsilon_t \sim t^*_{12.862985}$

$\delta_t = 0.003 + 0.133a^2_{t-1} + 0.067a^2_{t-2} + 0.063a^2_{t-3} + 0.048a^2_{t-4}$ $\delta_t = 0.003 + 0.135a^2_{t-1} + 0.074a^2_{t-2} + 0.055a^2_{t-3} + 0.040a^2_{t-4}$

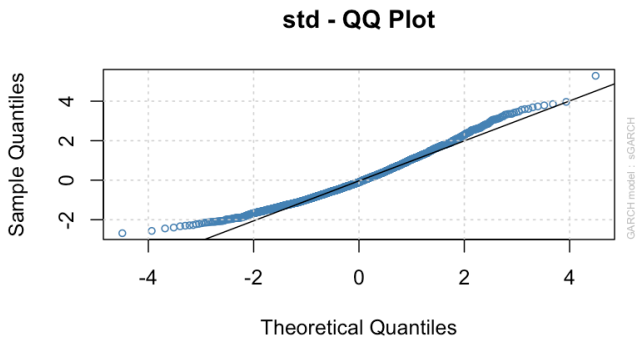

图 4.3　ARIMA(5,1,2)-ARCH(4) std QQ 图

对该模型的残差进行检验，用 KS 检验于 t 分布比较, 发现取 df=12 或 13 时 p-value < 2.2e-16，拒绝为 t 分布的假设，考虑重尾 t 分布。

新息为 sstd 分布模型为

$x_t = 0.292x_{t-1} + 0.042x_{t-2} + 0.163x_{t-3} + 0.120x_{t-4} - 0.056x_{t-5} + a_t - 0.787a_{t-1} - 0.202a_{t-2} \quad a_t = \delta_t\epsilon_t \quad \epsilon_t \sim t^*_{24.189}(1.423)$

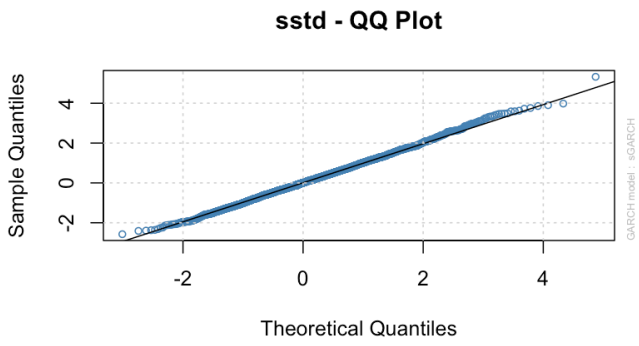

图 4.4　ARIMA(5,1,2)-ARCH(4) sstd QQ 图

从残差 QQ 图 4.4可以看出使用 sstd 的残差效果更好。

4.3　GARCH

由于 PACF 截尾较晚，我们考虑 GARCH(1,1)，同样地考虑 norm、std、sstd 三个分布，类似 ARCH 模型的结论可得出 sstd 是拟合最好的，由于均值是不显著的，模型为

$x_t = 0.236x_{t-1} + 0.025x_{t-2} + 0.126x_{t-3} + 0.113x_{t-4} - 0.042x_{t-5} + a_t - 0.788a_{t-1} - 0.188a_{t-2} \quad a_t = \delta_t\epsilon_t \quad \epsilon_t \sim t^*_{35.540}(1.438)$

$\delta_t = 0.057a^2_{t-1} + 0.907\delta^2_{t-1}$

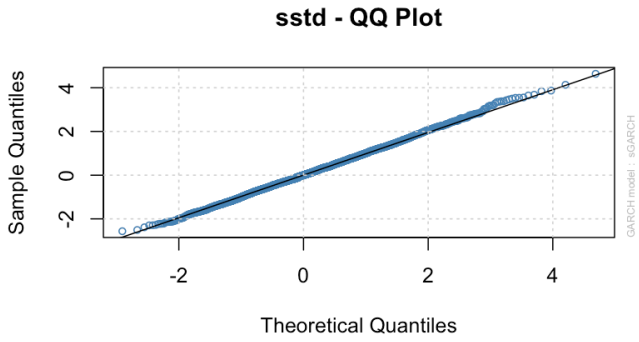

图 4.5　ARIMA(5,1,2)-GARCH(1,1) sstd QQ 图

结果与 ARIMA(5,1,2)-ARCH(4) 相近，即拟合高阶的 ARCH 也对模型没有很大的提升，我们考虑一些特殊的 GARCH 模型。

4.3.1　GARCH-M 效应

我们拟合 ARIMA-MGARCH 模型来看模型是否有 GARCH-M 效应，拟合的结果见表 4.2，残差图见 4.6，p 值大，ARCH-M 效应不显著。

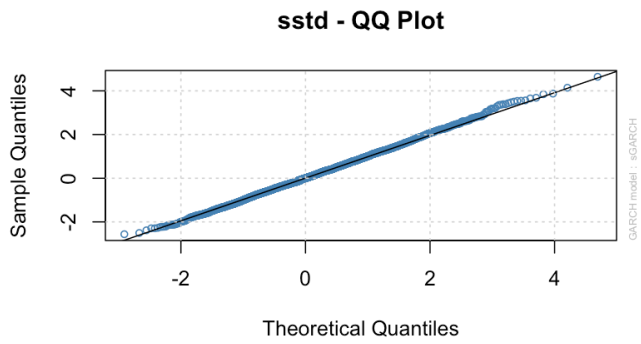

图 4.6　ARIMA(5,1,2)-MGARCH(1,1) sstd QQ 图

4.3.2　TGARCH 模型

表 4.2　GARCH-M 效应

变量名	Estimate	Std. Error	t value	Pr(>|t|)
ar1	0.236189	0.017247	13.69443	0.000000
ar2	0.024619	0.018335	1.34271	0.179365
ar3	0.126364	0.017817	7.09249	0.000000
ar4	0.112949	0.017144	6.58815	0.000000
ar5	-0.042250	0.017229	-2.45224	0.014197
ma1	-0.788405	0.000161	-4901.460073	0.000000
ma2	-0.187992	0.007087	-26.52540	0.000000
archm	-0.000143	0.017247	-0.64799	0.516994
omega	0.000144	0.000052	13.69443	0.000000
alpha1	0.056738	0.011975	4.73808	0.000002
beta1	0.906449	0.023127	39.19481	0.000000
skew	1.437939	0.041300	34.81695	0.000000
shape	35.185518	18.96942	1.85485	0.063617

我们拟合 ARIMA-TGARCH 模型来看模型是否有非对称效应，拟合的结果为

$x_t = 0.236x_{t-1} + 0.086x_{t-2} + 0.150x_{t-3} + 0.123x_{t-4} - 0.035x_{t-5} + a_t - 0.743a_{t-1} - 0.247a_{t-2} \quad a_t = \delta_t\epsilon_t \quad \epsilon_t \sim t^*_{30.402}(1.469)$

$\delta_t = 0.087 + (0.088 - 0.956N_{t-1})a^2_{t-1} + 0.907\delta^2_{t-1}$

该模型的 News-Impact Curve 如图 4.7，残差 QQ 图如图 4.8

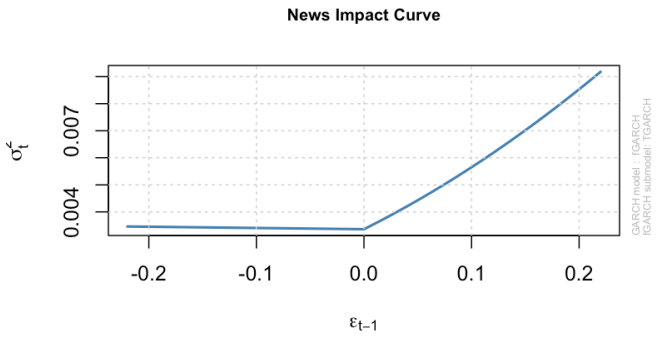

图 4.7　ARIMA(5,1,2)-TGARCH(1,1) sstd News-Impact Curve

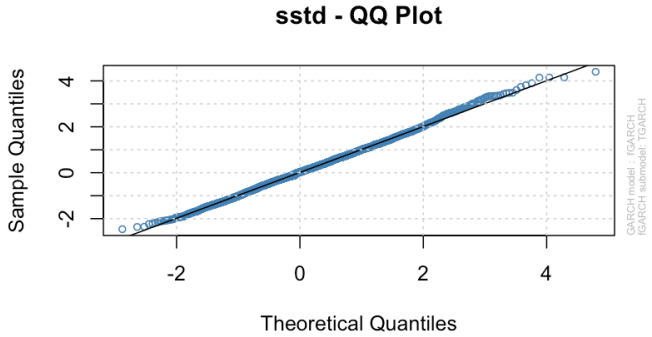

图 4.8　ARIMA(5,1,2)-TGARCH(1,1) sstd QQ 图

可以看出有明显的 TGARCH 效应且残差较好地符合假设。

因此最后选择的模型为 ARIMA-TGARCH(1,1) 残差为重尾 t 分布。由于以 AIC 为标准往往会高估模型阶数，以 BIC 为标准往往低估，且拟合 GATCH 模型时可能会使 ARIMA 的最佳阶数发生改变，因此我们在下一章中通过对 2019 年前 4 个月 120 个数据的滚动预测计算均方误差来选择最后的模型。

第 5 章　预测与模型选择

5.1　预测与选择

我们以 ARIMA-TGARCH 为模型，考虑了不同的阶数的 ARIMA 和 std,sstd 两个残差分布的模型，计算出的均方误差如下, 由于在 ARIMA-TGARCH 模型中均值均不显著且会影响收敛性，我们考虑不包含均值的 ARIMA-TGARCH

表 5.1　通过滚动预测选择模型

模型	ARIMA(1,1,1)(0,0,2)[7]	ARIMA(5,1,2)-TGARCH(1,1)	
残差	norm	norm	
MSE	0.004417017	0.004340805	
下列模型残差	norm	std	sstd
模型	ARIMA(5,1,2)	ARIMA(5,1,2)-TGARCH(1,1)	ARIMA(5,1,2)-TGARCH(1,1)
MSE	0.004338953	0.004306465	0.004417337
模型	ARIMA(4,1,4)	ARIMA(4,1,4)-TGARCH(1,1)	ARIMA(4,1,4)-TGARCH(1,1)
MSE	不平稳	0.004274643	0.004254391
模型	ARIMA(4,1,3)	ARIMA(4,1,3)-TGARCH(1,1)	ARIMA(4,1,3)-TGARCH(1,1)
MSE	不平稳	0.004253665	不收敛 [b]
模型	ARIMA(4,1,2)	ARIMA(4,1,2)-TGARCH(1,1)	ARIMA(4,1,2)-TGARCH(1,1)
MSE	0.004293264	0.004252834	**0.00421684**
模型	ARIMA(4,1,1)	ARIMA(4,1,1)-TGARCH(1,1)	ARIMA(4,1,1)-TGARCH(1,1)
MSE	0.004293281	0.00425007[a]	不收敛 [b]
模型	ARIMA(3,1,2)	ARIMA(3,1,2)-TGARCH(1,1)	ARIMA(3,1,2)-TGARCH(1,1)
MSE	0.004300545	0.004316782	0.004299433
模型	ARIMA(3,1,1)	ARIMA(3,1,1)-TGARCH(1,1)	ARIMA(3,1,1)-TGARCH(1,1)
MSE	0.004321143	0.004354528	0.004384729

[a] 需要以 2010-2018 年拟合参数为初值

[b] 指以默认或以 2010-2018 年拟合参数等为初值预测时存在不收敛的情况

从表 5.1 中可以看出 ARIMA(4,1,2)-TGARCH(1,1) 的均方误差最小，考虑第 4 章中的分析，选用此模型。

5.2　最终模型

最终模型为 ARIMA(4,1,2)-TGARCH(1,1)，残差为重尾 t 分布，表达式为

$$x_t = 0.327x_{t-1} + 0.043x_{t-2} + 0.174x_{t-3} + 0.102x_{t-4} + a_t - 0.844a_{t-1} - 0.157a_{t-2}$$

$$a_t = \delta_t \epsilon_t \quad \epsilon_t \sim t^*_{46.610}(1.536)$$

$$\delta_t = 0.011 + (0.088 - 1.000N_{t-1})a^2_{t-1} + 0.763\delta^2_{t-1}$$

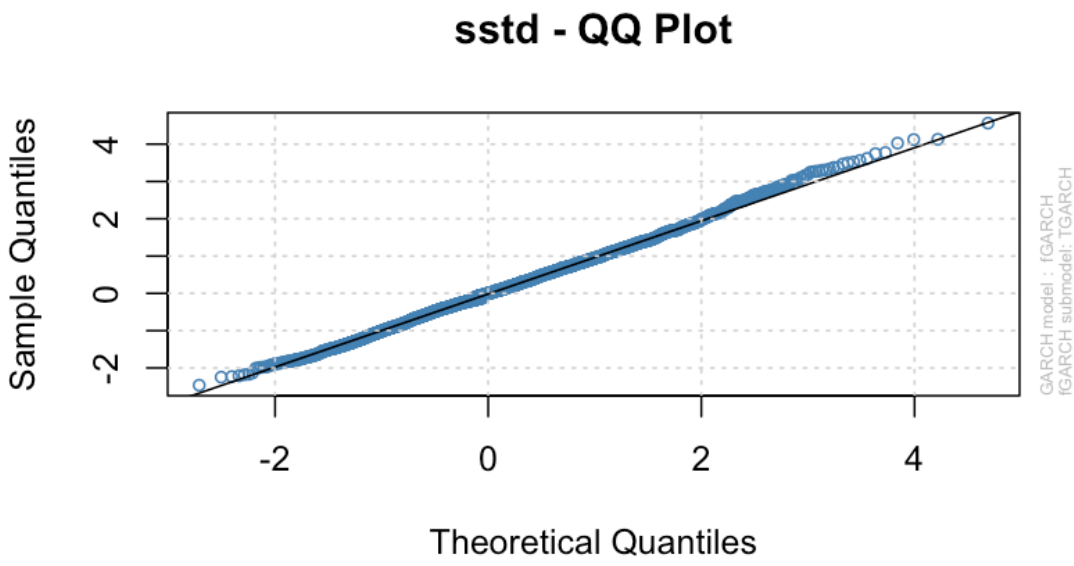

图 5.1　ARIMA(4,1,2)-TGARCH(1,1) sstd QQ 图

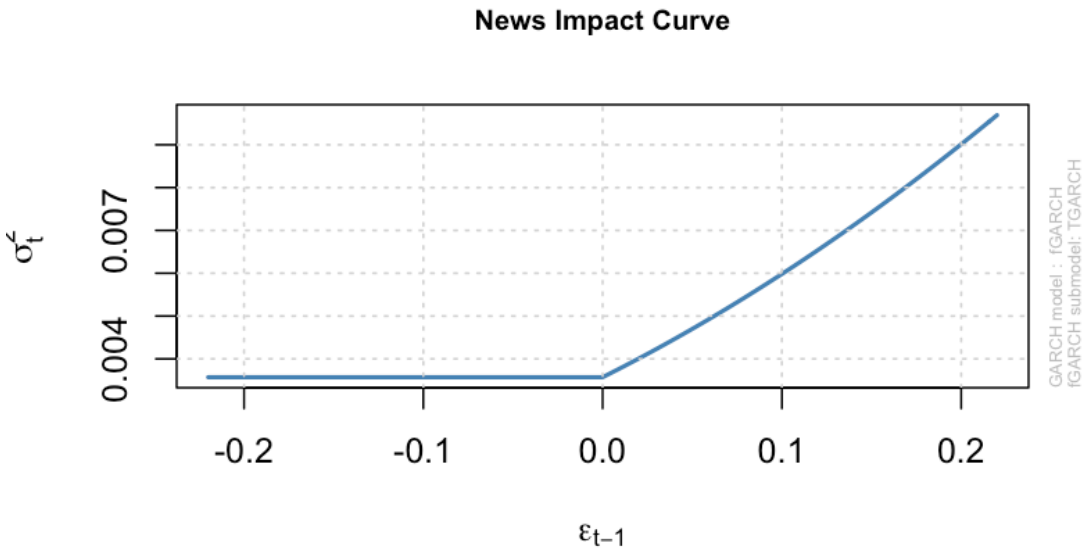

图 5.2　ARIMA(4,1,2)-TGARCH(1,1) sstd News-Impact Curve

该模型的残差图如图 5.1，可以看出残差基本为所设的重尾 t 分布；News-Impact Curve 如图 5.2，拟合的条件波动率如图 5.3。

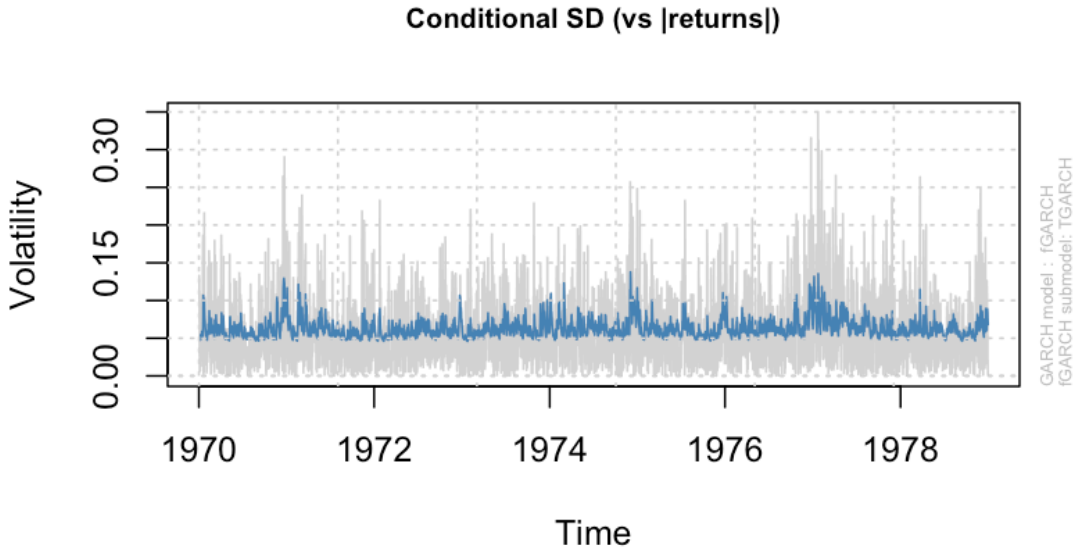

图 5.3　ARIMA(4,1,2)-TGARCH(1,1) sstd 波动率

该模型通过残差检验，又是 MSE 最小的，所以该模型最好地拟合了 ARR_DELAY 数据，模型对 2019 年 1-4 月的预测结果如图 5.4。

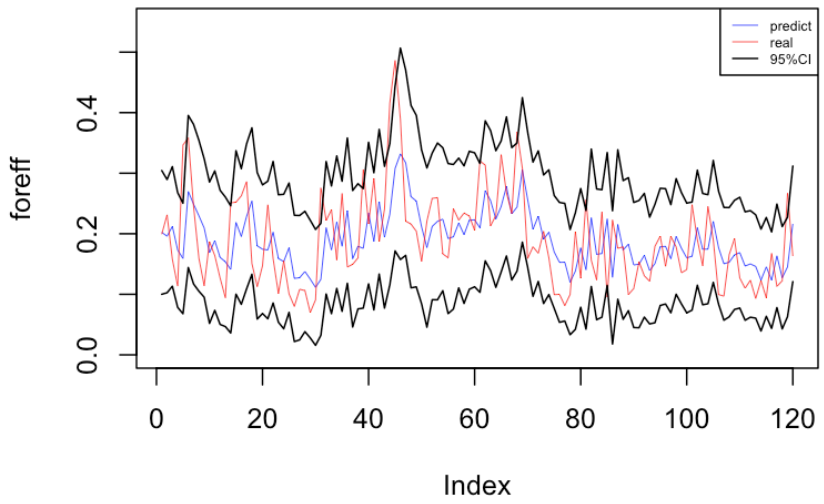

图 5.4　ARIMA(4,1,2)-TGARCH(1,1) sstd 预测

第 6 章　出发延误率建模

将处理 ARR_DELAY 的方法用于 DEP_DELAY，以 AIC 为准则拟合为 ARIMA(5,1,0)，以 BIC 为准则拟合为 ARIMA(2,1,1)，同样地经过分析发现新息样本应为重尾 t 的分布，GARCH-M 效应不显著，非对称性显著。因此在 ARIMA-TGARCH(1,1)，新息为重尾 t 分布的模型中通过滚动预测来选择模型。

表 6.1　通过滚动预测选择模型

模型	ARIMA(5,1,0)-TGARCH(1,1)	ARIMA(4,1,0)-TGARCH(1,1)
MSE	0.003306371	0.003354279
模型	ARIMA(3,1,0)-TGARCH(1,1)	ARIMA(3,1,1)-TGARCH(1,1)
MSE	0.003369415	**0.003105691**
模型	ARIMA(3,1,2)-TGARCH(1,1)	ARIMA(3,1,3)-TGARCH(1,1)
MSE	**0.003105691**	**0.003105691**
模型	ARIMA(2,1,1)-TGARCH(1,1)	ARIMA(2,1,2)-TGARCH(1,1)
MSE	0.003198808	0.003178566

distribution.model = ”sstd”

从表 6.1中知有三个模型的 MSE 均最小，我们选择参数较少的 ARIMA(3,1,1)-TGARCH(1,1) 模型为最终模型，模型为

$$x_t = 0.444x_{t-1} - 0.060x_{t-2} + 0.168x_{t-3} + a_t + 0.002a_{t-1} \quad a_t = \delta_t\epsilon_t \quad \epsilon_t \sim t^*_{33.108} \tag{1.354}$$

$$\delta_t = 0.011 + (0.054 - 0.364N_{t-1})a^2_{t-1} + 0.925\delta^2_{t-1}$$

该模型的标准化残差 QQ 图如图 6.1所示，标准化残差与所假定的重尾 t 分布相近，波动率拟合如图 6.2，News-Impact Curve 如图 6.3，2019 年 1-4 月的预测如图 6.4。

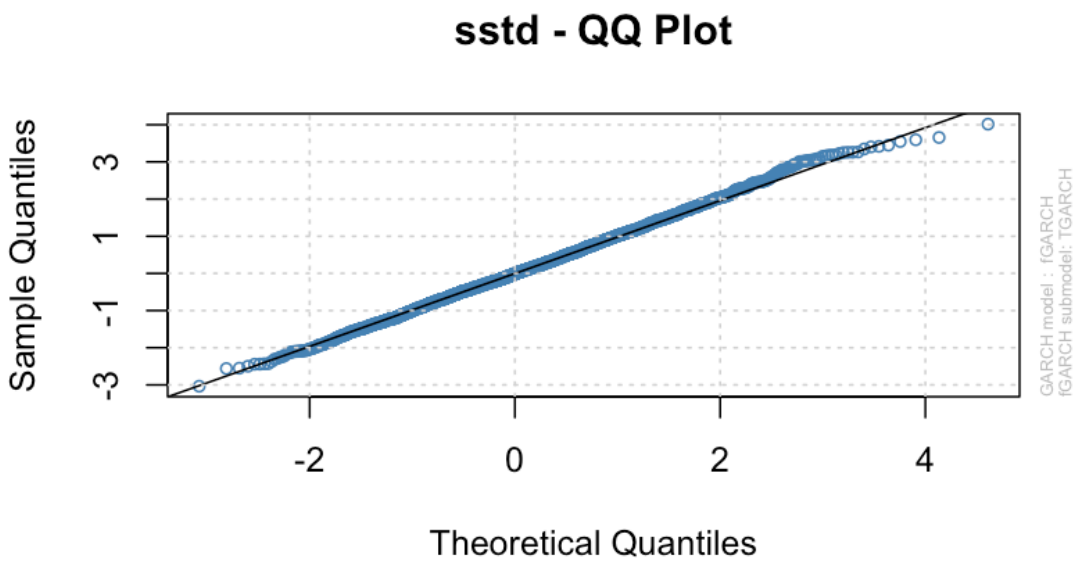

图 6.1　ARIMA(5,1,2)-TGARCH(1,1) sstd News-Impact Curve

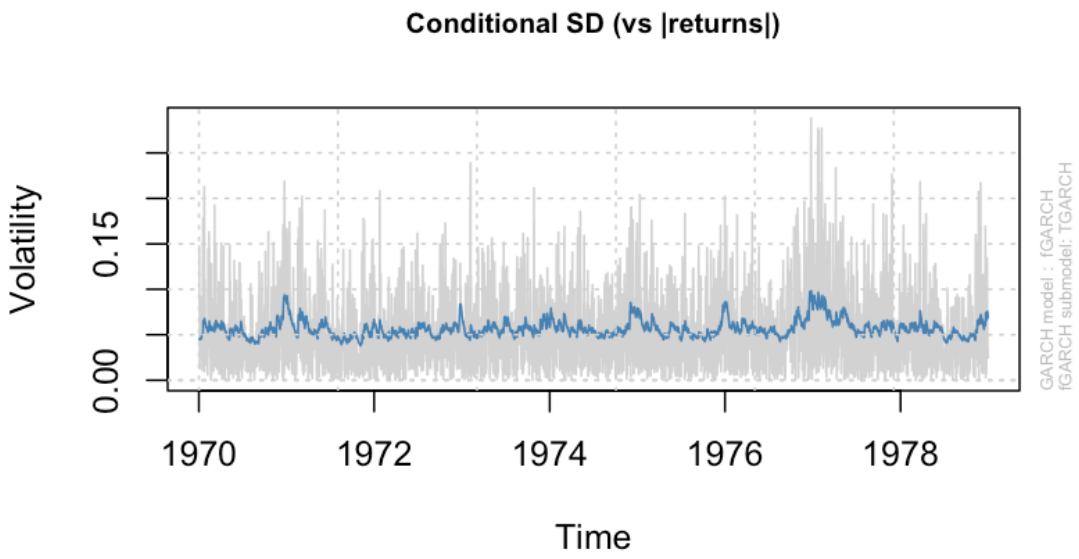

图 6.2　ARIMA(5,1,2)-TGARCH(1,1) sstd News-Impact Curve

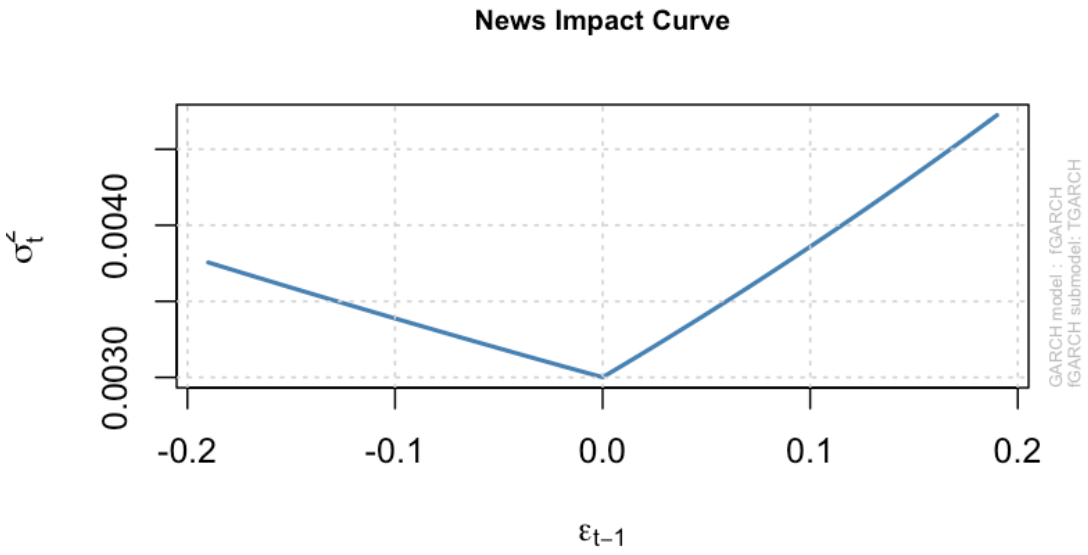

图 6.3　ARIMA(5,1,2)-TGARCH(1,1) sstd News-Impact Curve

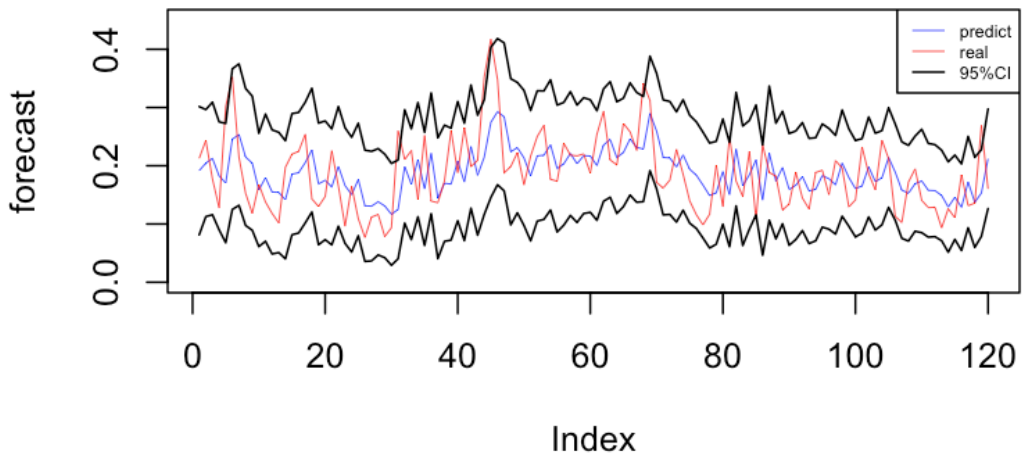

图 6.4　ARIMA(5,1,2)-TGARCH(1,1) sstd News-Impact Curve

该模型通过的残差检验，对 2019 年前四个月滚动预测的均方误差最小，因此该模型较好地拟合了数据。

第 7 章　结 果 分 析

7.1　模型分析

对于到达延误率，最终的模型说明当天的延误率的变化与前四天的延误率变化呈正相关，且前一天延误率的变化影响最大，重尾 t 分布表示了该模型取极端值的概率较大，TGARCH 效应显著，负的随机项对之后的变化影响更大，且两者影响方向相反。从直观上我们也能得到相似的结果，天气、罢工等影响有一定的持续性，例如前一天航班的延误可能导致航班堆积，且负的新息（例如天气好转）影响是更大的。

对于出发延误率，同样地当天的变化率与前一天的变化率呈明显的正相关，且，重尾 t 分布表示了该模型有较大的波动率，TGARCH 效应显著，负的新息对之后的变化影响更大，且两者影响方向相反。直观上的解释与到达延误率相同。

从上可以得出结论：总体来说，第二天的延误率和前一天的延误率是呈较为显著的正相关的，因此出行前可以查阅前一天的延误率以供参考。若前一天的延误率极端地低，那么后一天延误率的波动较大，旅客需要更为留意延误情况，若前一天的延误率极端高，那么后一天延误率高的概率更大，需要提前安排好行程。

7.2　对模型的一些展望

由于计算资源的限制我们仅根据 auto.arima 拟合结果对 ARIMA 阶数中的一小部分拟合了 ARIMA-TGARCH 模型，因此实验得到的可能不是在该问题上的最优解。

此外可以考虑拟合季节 ARIMA-GARCH 模型，但在本报告中并未实现，拟合较为复杂可以对原始数据进行其他方式的处理。

可以考虑 VAR 等其他模型，但需要做预处理，直接或差分后使用 VAR 模型拟合结果不理想

附录 A 补 充 材 料

用于处理原始数据的代码，以处理 2010-2018 年 DEP_DELAY 为例

```
#用y来表示计算出的延误率
y=numeric(0)
sapply(2010:2018,function(o){
  y=numeric(0)
  for(i in 1:12)
  {
    s1=paste0(o,"_",i)
    file_open=paste0("/Users/rain/Desktop/study/2018_2/时间序列/couseproject/flight/data/",s1,".csv")
    t=read.csv(file_open)
    #计算每天的延误航班数
    delay=tapply(I(t[,"DEP_DELAY"]>=15),t[,"FL_DATE"],sum,na.rm=TRUE)
    #计算每天的总机数
    all=tapply(t[,"DEP_DELAY"],t[,"FL_DATE"],length)
    计算延误率
    delayrate=delay/all
    y=c(y,delayrate)
  }
  #输出一年的数据
  file_write=paste0("/Users/rain/Desktop/study/2018_2/时间序列/couseproject/flight/DEP_DELAY/",o,".csv")
  write.csv(y,file=file_write)
})
```

所使用的保存图片函数

```
setwd("~/Downloads")
png('pic␣name', height=800,width=1000, res=150)
#pic code here
dev.off()
```

Model 部分代码

```
library(fGarch)
library(rugarch,quietly = TRUE)
```

```
library(forecast)
library(tseries)
library(fUnitRoots)#adfTest
#ARR_DELAY
data=read.csv("/Users/rain/Desktop/study/2018_2/时间序列/couseproject/flight/ARR_DELAY/ARR_DELAY.csv")
ARR_DELAY=ts(data[,2],start=c(2010,1,1),frequency=365.25)
plot.ts(ARR_DELAY,col="blue",lwd=0.5)
#自相关系数和偏相关系数
acf(ARR_DELAY)
pacf(ARR_DELAY)
#可以看出acf和pacf均拖尾
#单位根检验
adfTest(ARR_DELAY,lag=30)
adfTest(diff(ARR_DELAY),lag=30)
#可以看出做一阶差分后平稳
#均值是否为0的检验
t.test(ARR_DELAY)
#均值显著不为0，也即有明显的到达延误率

#差分后的数据分析
ARR_DELAY_diff=diff(ARR_DELAY)
plot.ts(ARR_DELAY_diff,col="blue",lwd=0.5)
acf(ARR_DELAY)
pacf(ARR_DELAY)
#acf拖尾，pacf有截尾趋势
#均值是否为0的检验
t.test(ARR_DELAY_diff)
#可以认为均值为0
#白噪声检验
Box.test(ARR_DELAY_diff,lag=30)
#拒绝白噪声的假设

#用auto.arima进行拟合，在auto.arima
fit1=auto.arima(ARR_DELAY)
summary(fit1)
#拟合结果为ARIMA(5,1,2)
tsdiag(fit1)

```

```
fit2=auto.arima(ARR_DELAY,ic='bic')
tsdiag(fit2)
#拟合结果为ARIMA(3,1,1)

Box.test(fit1$residuals^2)
Box.test(fit2$residuals^2)
#有明显的ARCH效应，考虑ARIMA-GARCH模型

#季节ARIMA
ARR_DELAY_week=ts(data[,2],frequency=7)
fit1=auto.arima(ARR_DELAY_week,seasonal=TRUE)
fit2=auto.arima(ARR_DELAY_week,seasonal=TRUE,ic="bic")
#ARIMA(1,1,1)(0,0,2)[7]

#ARCH模型
#ARCH定阶
pacf(fit1$residuals^2)
spec=ugarchspec(variance.model=list(garchOrder=c(4,0))
    ,mean.model=list(armaOrder=c(5,2), include.mean=
    FALSE),distribution.model = "norm")
fit_g1=ugarchfit(data=ARR_DELAY_diff,spec=spec)
plot(fit_g1,which=9)
#可以看出ARIMA-ARCH的拟合的效果较差,考虑其余的残差
spec=ugarchspec(variance.model=list(garchOrder=c(4,0))
    ,mean.model=list(armaOrder=c(5,2), include.mean=
    FALSE),distribution.model = "std")
fit_g1=ugarchfit(data=ARR_DELAY_diff,spec=spec)
plot(fit_g1,which=9)
spec=ugarchspec(variance.model=list(garchOrder=c(4,0))
    ,mean.model=list(armaOrder=c(5,2), include.mean=
    FALSE),distribution.model = "sstd")
fit_g1=ugarchfit(data=ARR_DELAY_diff,spec=spec)
plot(fit_g1,which=9)
#sstd更好


#GARCH模型
spec=ugarchspec(mean.model=list(armaOrder=c(5,2),
    include.mean=TRUE),distribution.model = "sstd")
fit_g1=ugarchfit(data=ARR_DELAY_diff,spec=spec)
```

```
plot(fit_g1,which=9)
#均值不显著
spec2=ugarchspec(mean.model=list(armaOrder=c(5,2),
    include.mean=FALSE),distribution.model = "sstd")
fit_g2=ugarchfit(data=ARR_DELAY_diff,spec=spec2)
fit_g2
plot(fit_g2,which=9)

#考虑GARCH-M
spec_garchm=ugarchspec(mean.model=list(armaOrder=c
    (5,2), include.mean=FALSE,archm=TRUE),distribution.
    model = "sstd")
fit_g3=ugarchfit(data=ARR_DELAY_diff,spec=spec_garchm)
#GARCH-M效应非常不显著

#考虑TGARCH
spec_tgarch=ugarchspec(variance.model=list(model="
    fGARCH",garchOrder=c(1,1),submodel="TGARCH"),mean.
    model=list(armaOrder=c(5,2),include.mean=FALSE,
    archm=FALSE),distribution.model = "sstd")
fit_g4=ugarchfit(data=ARR_DELAY_diff,spec=spec_tgarch)
plot(fit_g4,which=9)
#有一定的TGARCH效应
```

预测和模型选择部分代码

```
test_data=read.csv("/Users/rain/Desktop/study/2018_2/
    时间序列/couseproject/flight/ARR_DELAY/2019.csv")
data_all=c(data[,2],test_data[,2])
#ARIMA(5,1,2)
fore1=sapply(0:119,function(o){
  fit=arima(data_all[1:3287+o],order=c(5,1,2))
  c(forecast(fit,1)$mean,forecast(fit,1)$lower[2],
     forecast(fit,1)$upper[2])
})
MSE1=sum((fore1[1,]-test_data[,2])^2)/120
plot(fore1[1,],type="l",col="blue",lwd=0.5,ylim=c
    (0,0.55))
lines(test_data[,2],col="red",lwd=0.5)
lines(fore1[2,],lwd=0.5)
lines(fore1[3,],lwd=0.5)
```

```r

#ARIMA(5,1,2)-TGARCH(1,1) 采用sstd
spec_tgarch2=ugarchspec(variance.model=list(model ="
    fGARCH",garchOrder=c(1,1),submodel="TGARCH"),mean.
    model=list(armaOrder=c(5,2),include.mean=FALSE,
    archm=FALSE),distribution.model = "sstd")
fore4=sapply(0:119,function(o){
  fit=ugarchfit(data=diff(data_all[1:3287+o]),spec=
      spec_tgarch2)
  ugarchforecast(fit,n.ahead=1)@forecast[["seriesFor"
      ]]
})
fore44=fore4+data_all[3287:3406]
MSE4=sum((fore44-test_data[,2])^2)/120

#季节ARIMA
fore21=sapply(0:119,function(o){
  fit=arima(data_all[1:3287+o],order=c(1,1,1),seasonal
      =list(order=c(0,0,2),period=7))
  c(forecast(fit,1)$mean,forecast(fit,1)$lower[2],
      forecast(fit,1)$upper[2])
})
MSE21=sum((fore21[1,]-test_data[,2])^2)/120
```